Regresja liniowa i logistyczna

Uczenie Maszynowe
uczeniemaszynowe@cs.uni.wroc.pl

28.10.2025, 10:00
ćwiczenia

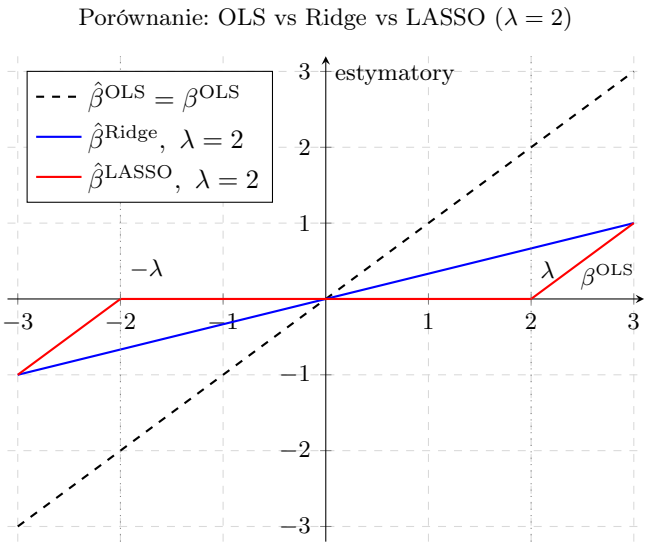

Rysunek 1: Zależność między współczynnikami regresji liniowej dla metody minimalizacji błędu średniokwadratowego, regularyzacji Ridge i LASSO.

Zadanie 1 [2.5 pkt]

Rozpatrzmy zbiór danych $\mathcal{D} = \{(y_i, x_i^{(1)}, x_i^{(2)})\}_{i=1}^{4}$, gdzie

i	$x_i^{(1)}$	$x_i^{(2)}$	y_i
1	1	0	2
2	0	1	2
3	1	1	3
4	2	0	4

Model regresji liniowej przyjmuje postać:

$$y = \beta_0 + \beta_1 x^{(1)} + \beta_2 x^{(2)} + \varepsilon.$$

1.5 pkt Oblicz współczynniki modelu regresji liniowej:

- 0.5 pkt minimalizując błąd średnio-kwadratowy,
- 0.5 pkt z regularyzacją Ridge,
- 0.5 pkt z regularyzacją LASSO.

1 pkt Opisz jak metody regularyzacji wpływają na parametry modelu. Wytłumacz to na przykłądzie Rynsunku 1. Która z regularyzacji może być postrzegana jako metoda wyboru zmiennych?

Wskazówki:

- Bądź gotowy do przedstawienia obliczeń na innym zbiorze danych w trakcie ćwiczeń.
- Opowiedz o gładkim ściąganiu współczynników regresji liniowej do zera i soft-thresholdingu.

Zadanie 2 [3 pkt]

Model regresji liniowej przyjmuje postać:

$$y = \beta_0 + \beta_1 x^{(1)} + \beta_2 x^{(2)} + \varepsilon,$$

gdzie $\varepsilon \sim \mathcal{N}(0, \sigma)$.

Dla danych z poprzedniego zadania oblicz estymator największej wiarogodności (MLE) dla:

- współczynników regresji liniowej β,
- odchylenia standardowego szumu σ lub wariancji,

Za rozwiązanie jednego podpunktu można uzyskać 2 pkt, za rozwiązanie obu podpunktów można uzyskać łącznie 3 pkt.

Wskazówki:

- Przypomnij sobie wzór na gęstość funkcji gęstości rozkładu normalnego oraz jak oblicza się wiarogodnośc (likelihood).
- Skorzystaj z faktu, że wiarogodność jest największa dokładnie wtedy, gdy jej logarytm jest największy.
- Oblicz pochodną (względem odpowiedniego parametru) i punkt stacjonarny.
- Nie zapomnij o drugiej pochodnej.
- Estymator współczynników regresji $\hat{\beta}$ zależy od y, zatem zależy od ε, czyli jest obarczony szumem. Odchylenie standardowe parametrów $\sigma^{\hat{\beta}}$ jest przekształceniem liniowym ochylenia standardowego szumu σ (przy ustalonych danych).
- Bądź gotowy(-a) do przeprowadzenia obliczeń na innych danych.

Zadanie 3 [1.5 pkt]

Jak sprawdzić, czy współczynniki regresji liniowej są statystycznie istotne, tzn. czy istotny jest wpływ danej zmiennej wyjaśniającej na zmienną objaśnianą? Zapoznaj się z poniższym opisem i sprawdź istotność współczynników regresji liniowej w poniższym przykładzie.

Wprowadzenie do Testowania Hipotez

Testowanie hipotez statystycznych to procedura statystyczna, która umożliwia ocenę dwóch konkurencyjnych twierdzeń na temat parametrów populacji na podstawie danych z próby.

Kluczowe Elementy

- **Hipoteza Zerowa (H_0):** Zawsze zakłada brak efektu, różnicy lub zależności. W kontekście regresji oznacza to, że dany współczynnik jest równy zero ($\beta_j = 0$).
- **Hipoteza Alternatywna (H_1):** Zakłada istnienie efektu lub zależności ($\beta_j \neq 0$).
- **Poziom Istotności (α):** Zazwyczaj ustalany na 0.05 (lub 5%). Jest to maksymalne dopuszczalne prawdopodobieństwo popełnienia błędu I rodzaju (odrzucenia prawdziwej hipotezy H_0, czyli fałszywego odkrycia). Testy konstruujemy tak, by minimalizować prawdopodobieństwo popełnienia błędu drugiego rodzaju (przyjęcia fałszywej hipotezy H_0, czyli niewykrycia istniejącego efektu) przy ustalonym poziomie istotności.
- **p-Wartość (p-value):** Prawdopodobieństwo zaobserwowania danych tak skrajnych lub bardziej skrajnych niż faktycznie zaobserwowane, przy założeniu, że H_0 jest prawdziwa.

Decyzja: Jeśli p-wartość $< \alpha$, odrzucamy H_0 na rzecz H_1, uznając wynik za istotny statystycznie. Równoważnie, możemy zdefiniować zbiór skrajnych statystyki testowej, dla których odrzucamy hipotezę zerową.

Rozkład t-Studenta (Student's t-distribution)

Jest to ciągły rozkład prawdopodobieństwa, który służy do wnioskowania statystycznego, zwłaszcza gdy wielkość próby (n) jest mała, a wariancja populacji jest nieznana (co jest typowe w regresji).

- **Kształt:** Jest symetryczny, dzwonowaty i ma grubsze "ogony"(większe prawdopodobieństwo skrajnych wartości) niż standardowy rozkład normalny.
- **Stopnie Swobody (ν):** Kształt rozkładu zależy od jednego parametru, którym są **stopnie swobody**. W regresji liniowej $\nu = n - p - 1$, gdzie n to liczba obserwacji, a p to liczba predyktorów.
- **Asymptotyczna Zbieżność:** W miarę jak liczba stopni swobody dąży do nieskończoności ($\nu \to \infty$), rozkład t-Studenta staje się praktycznie nieodróżnialny od standardowego rozkładu normalnego.

Test t-Studenta jako Narzędzie Oceny Istotności

Test t-Studenta jest wykorzystywany do testowania hipotez dotyczących populacji, gdy jej odchylenie standardowe jest nieznane, co jest typowe dla analizy współczynników regresji.

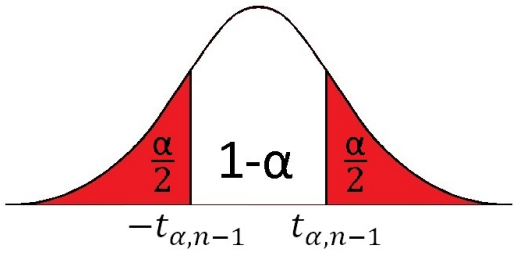

Rysunek 2: Rozkład t-Studenta z zaznaczonym obszarem krytycznym w teście przy poziomie istotności α. Źródło grafiki: https://www.statystyka-zadania.pl/wp-content/uploads/2014/03/t-student-dist-dystryb.jpg

Statystyka Testowa t

W kontekście ogólnym, statystykę t oblicza się jako:

$$t = \frac{\text{Estymator} - \text{Wartość Hipotetyczna}}{\text{Błąd Standardowy Estymatora}}$$

W kontekście regresji liniowej, gdzie chcemy sprawdzić, czy współczynnik β_j jest istotnie różny od zera, statystyka t dla estymowanego współczynnika $\hat{\beta}_j$ przyjmuje postać:

$$t = \frac{\hat{\beta}_j - 0}{SE(\hat{\beta}_j)} = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)}$$

gdzie $SE(\hat{\beta}_j)$ oznacza błąd standardowy estymowanego współczynnika.

Testowanie Istotności Parametrów Regresji Liniowej

Celem jest określenie, czy dany predyktor X_j w modelu regresji $Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p + \epsilon$ ma istotny wpływ na zmienną zależną Y.

Procedura Testowania Istotności Współczynnika β_j

1. **Sformułowanie Hipotez:**
   - $H_0 : \beta_j = 0$ (brak związku liniowego)
   - $H_1 : \beta_j \neq 0$ (istnieje związek liniowy)
2. **Obliczenie Statystyki t:** Korzystamy ze wzoru $t = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)}$.
3. **Wyznaczenie obszaru krytycznego:** Na podstawie rozkładu t-Studenta (o $n - p - 1$ stopniach swobody, gdzie n to liczba obserwacji, a p to liczba predyktorów), wyznaczamy kwantyl $t_\nu(\frac{\alpha}{2})$.
4. **Podjęcie Decyzji:** Porównnujemy czy moduł otrzymanej statystyki $|t|$ jest większy niż kwantyl $t_\nu(\frac{\alpha}{2})$, czyli sprawdzamy czy wpadamy do obszaru krytycznego.

Przykład do rozwiązania

Załóżmy, że estymujemy model badający wpływ **Wiek** (X_1) na **Dochód** (Y):

$$\text{Dochód} = \hat{\beta}_0 + \hat{\beta}_1 \cdot \text{Wiek} + e$$

Wyniki Estymacji na 30 próbkach jest $\hat{\beta}_1 = 0.8$ (oznacza, że wzrost wieku o rok jest związany ze wzrostem dochodu o 0.8 jednostki) oraz $SE(\hat{\beta}_1) = 0.3$ (odchylenie standardowe rozkładu estymatora β_1). Przetestuj istotność tego współczynnika. Kwantyle rozkładu t-Studenta znajdziesz np. tutaj: https://pl.wikisource.org/wiki/Tablica_rozk%C5%82adu_t-Studenta.

Zadanie 4 [2 pkt]

Firma medyczna opracowuje model diagnostyczny do wykrywania rzadkiej choroby X. Choroba X występuje u około 2% populacji. W badaniu walidacyjnym wzięło udział 1000 pacjentów, wśród których 20 faktycznie miało chorobę, a 980 jej nie miało. Model przewiduje obecność choroby u 50 pacjentów, z czego 15 faktycznie chorowało, a 35 było zdrowych.

	Choroba X = Tak	Choroba X = Nie
Predykcja = Tak	TP	FP
Predykcja = Nie	FN	TN

Tabela 1: Macierz pomyłek (Confusion Matrix) modelu diagnostycznego

0.25 pkt Uzupełnij macierz pomyłek w Tabeli 1.

5 × 0.2 pkt Podaj definicje/wzory następujących metryk. Oblicz wartości metryk. Zinterpretuj otrzymane wyniki w kontekście diagnozowania rzadkiej choroby.

- Accuracy (dokładność)
- Precision (precyzja)
- Recall (czułość, sensitivity)
- Specificity (swoistość)
- F1-score

0.5 pkt Jakie metryki są tutaj najbardziej informatywne i dlaczego? Podaj inne przykłady ze świata rzeczywistego, kiedy mamy do czynienia z klasami niezbalansowanymi.

0.25 pkt Jaki poziom dokładności możemy uzyskać trywialnym klasyfikatorem (i jaki to klasyfikator)?

Zadanie 5 [1 pkt]

Dana jest funkcja $f(x) = x^2 + 2x$. Przeprowadź 2 kroki algorytmu gradient descent dla punktu początkowego $x_0 = 2$ i learning rate $\eta = 0.3$.

Dyskusja na pracownię

- Jakich innych niż MSE metryk można użyć do oceny regresji?
- Czym różni się parametr of hiperparametru? Jak dobrać odpowiednie η?
- Jak odpowiednio podzielić dane w przypadku klas niezbalansowanych?
- Jakie trudności można napotkać stosując GD w uczeniu maszynowym? Jakie są nowoczesne metody optymalizacji?